



Teknoloji Fakültesi

BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

FATURALARIN OTOMATİK OLARAK ANALİZ EDİLMESİ ve SINIFLANDIRILMASI

BİTİRME PROJESİ

Bilgisayar Mühendisliği Bölümü

DANIŞMAN

Dr. Öğr. Üyesi Ayşe Berna ALTINEL



ÖNSÖZ

Proje çalışmamız süresince karşılaştığımız bütün problemlerde sabırla yardım ve bilgilerini esirgemeyen, tüm desteğini sonuna kadar yanımda hissettiğim değerli hocamız Dr. Öğr. Üyesi Ayşe Berna Altınel'e, bu proje fikrinin oluşması ve ortaya çıkmasındaki öneri ve desteğinden dolayı ayrıca teşekkür eder, maddi ve manevi desteklerini esirgemeyen okul içindeki ve dışındaki değerli çalışma arkadaşlarım ve hocamıza sonsuz teşekkürlerimizi sunarız.

İÇİNDEKİLER

1. GİRİŞ	7
1.1. Proje Çalışmasının Amacı ve Önemi	7
2. FATURA VERİLERİ ÜZERİNDE OCR TABANLI ANALİZ YÖNTEMLERİ	9
2.1. Kullanılan Teknolojiler ve Uygulama Süreci	9
2.2. Görüntü İşleme Tekniklerinin OCR Performansına Etkisi	12
3. YAPILAN ÇALIŞMALAR VE PLANLAMA	Hata! Yer işareti tanımlanmamış.
3.1. Şu Ana Kadar Yapılanlar	Hata! Yer işareti tanımlanmamış.
3.2. Sonraki Aşamada Planlananlar	Hata! Yer işareti tanımlanmamış.
4. SONUÇLAR	17
4.1. Genel Değerlendirme ve Kazanımlar	17

ÖZET

FATURALARIN OTOMATİK OLARAK ANALİZ EDİLMESİ VE SINIFLANDIRILMASI

Bu projede, fatura belgelerinin dijital ortamda işlenmesi ve sınıflandırılması amacıyla optik karakter tanıma (OCR) ve makine öğrenmesi tabanlı bir sistem geliştirilmiştir. Faturalardan metin çıkarımı, görsel ön işleme teknikleri, model eğitimi ve sınıflandırma süreçleri sistematik olarak ele alınmış ve bir prototip geliştirilmiştir. Bu raporda proje sürecinde şu ana kadar gerçekleştirilen çalışmalar ve ilerleyen aşamalarda yapılması planlanan adımlar detaylı olarak sunulmaktadır.

Mart, 2025

Öğrenciler

İsmail Mert Akpınar
Gürkan Çelen
Yunus Alp Turan
Ahmed Said Kılıç

ABSTRACT

AUTOMATIC ANALYSIS AND CLASSIFICATION OF INVOICES

This project aims to develop a system based on Optical Character Recognition (OCR) and machine learning to automatically analyze and classify utility bills. The increasing volume of digital documentation in enterprises has made automated data extraction and classification from financial documents such as invoices and bills a critical need for efficiency, accuracy, and digital transformation.

In the proposed system, text is extracted from scanned or photographed invoice images using Tesseract OCR, an open-source and widely adopted tool. Prior to OCR, a comprehensive image preprocessing pipeline is applied to significantly enhance the recognition accuracy. This pipeline includes grayscale conversion, Gaussian blurring for noise reduction, edge detection using the Canny algorithm, perspective correction to fix skewed inputs, and adaptive thresholding to increase the contrast between text and background.

After text extraction, post-processing steps such as spelling correction using SpellChecker are performed to improve data quality. The processed text is then prepared for classification using traditional machine learning algorithms like Logistic Regression and Naive Bayes, as well as more advanced models including Convolutional Neural Networks (CNNs) and transformer-based architectures in the later stages.

This interim report presents the progress achieved so far, including the successful integration of OCR with preprocessing techniques, early experimentation with text classification models, and the plan for expanding the dataset and improving classification accuracy in the next phase. The results indicate a substantial improvement in OCR performance due to preprocessing, with accuracy rates rising from around 70% to over 90%.

The final system is envisioned to be capable of recognizing different bill types (electricity, water, gas, etc.), extracting relevant information, and classifying documents effectively. The outcomes of this project are expected to be applicable both in academic research and

in real-world enterprise automation scenarios.

March, 2025

Students

İsmail Mert Akpınar
Gürkan Çelen
Yunus Alp Turan
Ahmed Said Kılıç

ŞEKİL LİSTESİ

Şekil 1.1 Doğada bulunan maddelerin yaklaşık olarak boyutları ve bu maddeleri algılamak-görselleştirmek için gerekli olan algılayıcılar	2
Şekil 2.1 Nokta yayılım fonksiyonunun görüntü üzerindeki etkisi	5
Şekil 4.1 Yapılandırılmış aydınlatma mikroskopisi deney düzeneği	6
Şekil 4.2 DLP3000 geliştirme modülü	7
Şekil 4.23 MATLAB-CUDA arasında mexcuda fonksiyonu ile parametre geçişi ve haberleşme mimarisi	8

TABLO LİSTESİ

Tablo 4.1 Deney çalışmalarında kullanılan bilgisayarın özellikleri	6
Tablo 4.4 SIM yöntemi için geliştirilen CUDA çekirdek fonksiyonlarının listesi	7

1. GİRİŞ

Son yıllarda veri üretiminin hızla artması ve şirketlerin dijital ortamda işlemleri gereken belgelerin yoğunlaşması, finansal dokümanların yönetimini kritik hale getirmiştir. Özellikle faturaların manuel olarak işlenmesi, kurumlar için yüksek maliyetler ve veri giriş hatalarını beraberinde getirmekte, karar alma süreçlerinde gecikmelere neden olmaktadır. Bu nedenle fatura gibi finansal belgelerin dijital ortamda otomatik analiz edilmesi ve sınıflandırılması, işletmelerin rekabet avantajını artırmak ve operasyonel süreçlerini hızlandırmak için kaçınılmaz bir ihtiyaç olarak karşımıza çıkmaktadır.

Bu bağlamda, "Faturaların Otomatik Olarak Analiz Edilmesi ve Sınıflandırılması" projesinde optik karakter tanıma (OCR) ve makine öğrenmesi teknolojileri entegre edilerek faturaların dijitalleştirilmesi hedeflenmiştir. Fatura görüntülerinden metin çıkarımı yapabilmek için çeşitli görüntü ön işleme teknikleri incelenmiş, farklı OCR modelleri karşılaştırılarak doğruluk oranı en yüksek olan yöntem seçilmiştir. Ayrıca çıkarılan metinlerin sınıflandırılması amacıyla, hem geleneksel hem de modern makine öğrenmesi yaklaşımları değerlendirilmiş ve proje kapsamına uygun bir model geliştirilmiştir. Bu çalışma sonucunda, geliştirilen sistemin farklı türden belgelerin analizinde de kullanılabilirliği sağlanarak, gelecekte daha geniş kapsamlı uygulamalara zemin hazırlanmıştır.

1.1. Proje Çalışmasının Amacı ve Önemi

Projenin temel amacı, işletmelerdeki fatura süreçlerini OCR ve makine öğrenmesi tabanlı sistemlerle dijital ortama taşıyarak, kurumların veri analizi ve raporlama süreçlerini kolaylaştırmaktır. Özellikle büyük ölçekli şirketlerde manuel belge işleme süreçleri yüksek maliyetlere ve hata risklerine neden olurken, geliştirilen bu sistem ile veri giriş hızını ve doğruluğunu artırmak amaçlanmaktadır.

Geliştirilen sistem sayesinde faturaların dijital ortamda sınıflandırılması ve içerik analizlerinin hızlı bir biçimde gerçekleştirilmesi mümkün hale gelmiştir. Böylece şirketler, daha hızlı ve hatasız finansal veri elde ederek karar alma süreçlerini güçlendirmektedir. Ayrıca, çalışmanın sağladığı dijital altyapı sayesinde gelecekte farklı belge türleri için de benzer otomatik analiz ve sınıflandırma çözümlerinin geliştirilmesine olanak tanınmaktadır.

Projenin önemi, yalnızca operasyonel süreçlerde sağladığı iyileştirmelerle sınırlı değildir. Aynı zamanda akademik literatüre OCR ve makine öğrenmesi entegrasyonu konusunda yeni bulgular sunması ve dijital dönüşüm alanındaki uygulamalara örnek teşkil etmesi açısından da değerlidir.

2. FATURA VERİLERİ ÜZERİNDE OCR TABANLI ANALİZ YÖNTEMLERİ

OCR (Optik Karakter Tanıma) tabanlı analiz sistemleri, sayısal belge içeriklerinin otomatik olarak okunmasını, yapılandırılmasını ve dijital sistemler tarafından yorumlanabilir hale getirilmesini sağlar [1]. Bu kapsamda, fatura gibi belgelerde yer alan metinsel içerikler, çeşitli görüntü işleme ve makine öğrenmesi teknikleri kullanılarak analiz edilir. Fatura üzerindeki metinlerin çoğu zaman insan gözüyle kolayca seçilemeyecek düzeyde düşük çözünürlükte, bulanık ya da farklı ışık koşullarında taranmış olması, OCR sistemlerinin görüntüleme kalitesine ve algoritmalarına olan bağımlılığını artırmaktadır.

Bir OCR sisteminin temel yapısı, tıpkı bir optik mikroskobun görüntüleme sistemi gibi iki aşamada incelenebilir. İlk aşama, belgenin görüntü olarak yakalanması ve işlenmesidir. Bu işlem genellikle düz aydınlatma (wide field illumination) veya adaptif kontrast artırma teknikleriyle gerçekleştirilir. İkinci aşama ise bu görüntüden fotonik bilgiye karşılık gelen piksellerin işlenmesi ve karakterlerin tanınmasıdır. Bu adımda, görüntü sensörleri (kamera, foto-sensörler, CMOS/CCD) tarafından alınan veri dijital hale getirilir ve metin çıkarımı gerçekleştirilir.

Görüntüleme sisteminin davranışı matematiksel olarak bir dürtü cevabı (impulse response) modeliyle temsil edilebilir. OCR sisteminde elde edilen görüntü, orijinal metinsel içeriğin, sistemin uzamsal çözünürlüğünü belirleyen nokta yayılım fonksiyonu (PSF) ile konvolüsyona uğraması sonucu oluşur. PSF, ideal bir noktasal karakterin sistemden nasıl geçtiğini modelleyen yapıdır ve OCR doğruluğunu doğrudan etkiler.

Bu eşitlik, elde edilen OCR görüntüsünün ideal metin dağılımının sistemsel bulanıklık fonksiyonu (PSF) ile konvolüsyona uğradığını belirtir. PSF'nin Fourier dönüşümü alınarak elde edilen optik transfer fonksiyonu (OTF), OCR sisteminin frekans uzayındaki performans limitlerini tanımlar. OTF'nin tanımladığı geçiş bandı dışında kalan yüksek frekans bileşenleri (örneğin ince karakter detayları veya kenar geçişleri), OCR sonucunda kaybolabilir. Elde edilen görüntü frekans uzayında aşağıdaki gibi temsil edilir:

Eğer sistem ideal dışı koşullarda çalışıyorsa (düşük çözünürlük, bozuk odaklama, aydınlatma eksikliği gibi), OCR süreci gürültüye maruz kalabilir.

OCR sisteminde elde edilen sonuç, ideal PSF'ye sahip bir optik sistem ile modellenmiş olsaydı, karakter kenarlarının netliği ve OCR başarımları maksimuma ulaşır. Ancak pratikte, kullanılan kameranın çözünürlüğü, belge üzerindeki mürekkep kalitesi, aydınlatma homojenliği gibi faktörler bu ideal durumu bozmakta ve sistem çıktısını etkilemektedir.

2.1. Kullanılan Teknolojiler ve Uygulama Süreci

Bu çalışmada, fatura belgeleri üzerinde metin tanıma ve içerik sınıflandırma işlemlerini gerçekleştirmek amacıyla, derin öğrenme tabanlı bir OCR sistemi olan Keras-OCR kullanılmıştır. Uygulama süreci, klasik görüntü işleme yöntemleriyle görselin ön işlenmesini takiben, elde edilen iyileştirilmiş görüntülerin Keras OCR modeline aktarılması biçiminde gerçekleştirilmiştir. Bu bütünlük yapı sayesinde, metin tespiti öncesinde gürültü azaltma, kenar belirleme ve perspektif düzeltme gibi işlemler uygulanarak OCR modelinin doğruluk oranı artırılmıştır.

2.1.1. Görüntü Ön İşleme Süreci

Fatura görüntüleri genellikle düşük çözünürlükte taranmakta veya mobil cihaz kameraları aracılığıyla farklı açılardan elde edilmektedir. Bu durum, OCR motorlarının doğru tanıma gerçekleştirmesini zorlaştıran temel faktörlerden biridir. Bu nedenle, OCR motoruna aktarılmadan önce görüntülerin çeşitli görüntü işleme teknikleri ile iyileştirilmesi gerekmektedir.

Uygulanan başlıca ön işleme adımları şu şekildedir:

- **Gradyan Tabanlı Kenar Tespiti:** Canny kenar tespit algoritması ile görüntüdeki metinsel yapıların dış sınırları belirginleştirilmiştir. Bu sayede kontur tespiti ile belge sınırları tespit edilerek perspektif düzeltme yapılabilmektedir.
- **Gaussian Filtresi ile Gürültü Azaltma:** Görüntüdeki yüksek frekanslı parazitler, Gauss bulanıklaştırma filtresi ile giderilerek karakter yapılarının daha net algılanması sağlanmıştır.
- **Adaptif Thresholding:** Varyasyon gösteren aydınlatma koşulları altında daha stabil karakter tespiti için adaptif eşikleme (örn. Gaussian thresholding) kullanılmıştır.

- **Perspektif Düzeltme (Homografik Transformasyon):** Belge eğriliğini veya yatay-düşey bozulmaları düzeltmek amacıyla kontur analizine dayalı bir dörtgen tespit algoritması uygulanmış ve belgeyi yeniden hizalayan bir homografik dönüşüm gerçekleştirilmiştir.

2.1.2. OCR ile Metin Tanıma ve Çıkarım Süreci

Görüntü ön işleme adımını takiben, görüntüden metin çıkarımı işlemi gerçekleştirilmiştir. Bu aşamada hem geleneksel karakter tanıma algoritmalarına (pytesseract) hem de modern derin öğrenme temelli yaklaşımlara (Keras OCR) dayalı yöntemler değerlendirilmiştir.

Keras OCR mimarisi, karakter algılama ve tanıma işlemini iki aşamada gerçekleştiren bir end-to-end derin öğrenme tabanlı sistemdir:

1. **Detection (Tespit):** Karakter içeren bölge veya kutucukların tespiti için Convolutional Neural Network (CNN) tabanlı bir bölge öneri ağı kullanılır.
2. **Recognition (Tanıma):** Her bir kutu içerisindeki karakter dizisi, bir RNN/LSTM veya CRNN model aracılığıyla sıralı olarak çözülür [2].

Bu sistemin en temel avantajı; bozulmuş, el yazısı benzeri veya düzensiz karakter yapılarında dahi yüksek başarı ile çalışabilmesidir. Uygulanan normalize etme adımı, Türkçe karakterlerin ASCII karşılıklarına dönüştürülmesi işlemini de içermektedir. Bu işlem metin madenciliğinde standardizasyon sağlamak amacıyla yapılmıştır.

2.1.3. Anahtar Kelime Tabanlı Kategori Sınıflandırması

OCR sonucu elde edilen metinsel veri üzerinde, kelime bazlı analiz gerçekleştirilmiştir. Her bir fatura, içerdiği kelimelere göre belirlenen kategori anahtar kelimeleriyle karşılaştırılmış ve her kategori için bir benzerlik skoru hesaplanmıştır [3]. Buradaki temel varsayım, fatura üzerinde geçen marka, ürün, hizmet ya da işlem terimlerinin kategori ayrımı yapmada ayırt edici olduğu bilgisidir.

Skoru en yüksek olan kategori, fatura sınıfı olarak atanmakta ve sistem çıktısı olarak kullanıcıya sunulmaktadır. Bu yapı, temel bir “bag-of-keywords” yaklaşımına dayansa da sistematik ön işleme ve OCR desteğiyle yüksek doğruluk oranı elde edilmiştir.

2.2. Görüntü İşleme Tekniklerinin OCR Performansına Etkisi

Skoru en yüksek Optik karakter tanıma (OCR) sistemlerinin başarı oranı, doğrudan görüntü kalitesine ve belge üzerindeki metinsel bileşenlerin algılanabilirliğine bağlıdır. Gerçek dünyadan elde edilen fatura görüntüleri; düşük çözünürlük, ışık yansımaları, gölgeler, eğiklik, parazit, arka plan karmaşası gibi çeşitli bozunumlara maruz kalmakta ve bu durum OCR performansını olumsuz etkilemektedir.

Bu nedenle OCR'dan önce gerçekleştirilen görüntü işleme teknikleri, sistemin doğruluk oranını artırmada kritik bir rol oynamaktadır. Görüntü ön işleme adımları, görüntüdeki metinsel bileşenlerin öne çıkarılması, arka planın bastırılması ve karakter sınırlarının belirginleştirilmesi hedefiyle tasarlanmaktadır. Bu bağlamda uygulanan işlemler teorik ve deneysel olarak aşağıda detaylandırılmıştır:

2.2.1. Gürültü Azaltma ve Kenar Güçlendirme

Görüntülerin üzerinde yer alan yüksek frekanslı rastgele pikseller, OCR motorunun karakter sınırlamalarını doğru biçimde belirlemesini zorlaştırmaktadır. Bu nedenle öncelikle Gauss bulanıklaştırma (Gaussian Blur) filtresi uygulanarak, bu tür parazit bileşenlerin etkisi azaltılmıştır. Gauss filtresi, görüntü üzerinde yumuşak geçişler sağlayarak, ani yoğunluk değişimlerini bastırır.

Filtre uygulamasının ardından morfolojik genişletme (dilation) işlemi ile karakter kenarları güçlendirilmiştir. Özellikle ince yazı tipleri ya da soluk yazılar için dilation işlemi karakter yapılarının birbirinden ayrılabilirliğini artırmakta etkilidir.

2.1.2. Kontur Tespiti ve Perspektif Dönüşüm

Fatura görüntüleri genellikle telefon kamerası ile çekildiğinden, belge sınırları eğilmiş ya da perspektif bozulmasına uğramış olabilir. Bu durum OCR motorlarının metinleri satır-satır ve blok-blok doğru şekilde ayrıştırmasını engeller.

Bu problemi çözmek amacıyla, Canny kenar tespit algoritması uygulanmış, ardından tespit edilen kenarlardan en büyük konturlar analiz edilmiştir. Dört köşeli yapıya sahip en büyük kontur, belge sınırı olarak kabul edilmiş ve bu kontur kullanılarak homografik dönüşüm uygulanmıştır.

Bu işlem sonucunda belge görüntüsü yeniden hizalanarak, optik olarak düzgün bir dikdörtgen haline getirilmiştir. Bu düzeltme işlemi, OCR'nin satır tabanlı ayrıştırma mantığını doğrudan desteklemektedir.

2.1.3. Adaptif Eşikleme ve Siyah-Beyaz Dönüşüm

OCR algoritmalarının çoğu, siyah-beyaz (binary) görüntüler üzerinde daha yüksek doğrulukla çalışmaktadır. Ancak sabit eşikleme teknikleri (örneğin global thresholding), değişken ışık koşullarına sahip görüntülerde başarısız olmaktadır. Bu sebeple çalışmada adaptif eşikleme (adaptive thresholding) yöntemi tercih edilmiştir.

Burada kullanılan Gaussian-weighted local thresholding yöntemi, her piksel için komşuluk penceresi üzerinden lokal bir eşik belirlemekte ve bu eşik ile karar vermektedir. Böylece hem karanlık hem de aydınlık alanlarda yazı netliği korunmaktadır. Bu işlem sonrası fatura görüntüsü siyah-beyaz hale getirilmiş ve OCR işlemine hazır hale getirilmiştir.

3. YAPILAN ÇALIŞMALAR VE PLANLAMA

3.1. Şu Ana Kadar Yapılanlar

Proje kapsamında, pazar fişlerinin optik karakter tanıma (Optical Character Recognition, OCR) işlemine hazır hale getirilmesi için öncelikle görüntülerdeki fişlerin tespit edilip çerçevelenmesi gerçekleştirilmiştir. Bu amaçla, standart dikdörtgen sınırlayıcı kutular yerine dönük sınırlayıcı kutular (oriented bounding boxes) kullanan YOLOv5-OBb modeli entegre edilmiştir. YOLOv5-OBb, YOLOv5 modelinin açılı nesneleri de kapsayacak şekilde döndürülmüş kutularla tespit yapabilen bir varyantıdır ve açılı konumlanmış nesneleri daha sıkı ve doğru şekilde çerçevelemek üzere tasarlanmıştır [4]. Böylece gerçek dünya görüntülerinde eğik veya döndürülmüş olabilen fişlerin, arka plan fazlalığı veya birden fazla nesneyi tek kutuda barındırma sorunu olmadan yakalanması hedeflenmiştir [5].



Şekil 1



Şekil 2

Şekil 1: Geleneksel eksen-hizalı kutularla nesne tespiti örneği. Açılı nesneler tam oturmadığından, tek bir kutu birden çok cismi içerebilmektedir (kırmızı kutular birden fazla kapsülü kapsıyor).

Veri seti hazırlığı için Clova AI tarafından sağlanan CORD veri seti ve Roboflow'un Receipt Segmentation veri seti kullanılmıştır. CORD, mağaza ve restoranlardan toplanmış 11.000'den fazla fiş görüntüsü içeren kapsamlı bir veri kümesidir [6] ve OCR ile sonrasındaki analiz görevleri için kutu/metin anotasyonları barındırmaktadır. Roboflow'da sunulan Receipt Segmentation veri seti ise yaklaşık 365 adet açık kaynak fiş görüntüsünü içermekte ve fiş segmentasyonu için önceden eğitilmiş bir model ile birlikte gelmektedir [7]. Bu iki veri seti üzerinde proje gereksinimlerine uygun olacak şekilde anotasyon çalışmaları yürütülmüş ve YOLOv5-OBB modelinin eğitimi başlatılmıştır. Model eğitimi devam etmekte olup, erken aşamada alınan sonuçlar modelin eğik pozisyonlu fişleri başarıyla tespit edebileceğini göstermektedir.

Fiş görüntüleri tespit ve kırpma işlemlerinin ardından OCR için ön işleme tabi tutulmaktadır. Öncelikle görüntü gürültüsünü azaltmak için Gauss bulanıklaştırma (Gaussian blur) uygulanmakta, ardından fiş kenarlarının belirginleştirilmesi amacıyla kenar tespiti (edge detection) yapılmaktadır. Tespit edilen kenar veya köşe bilgilerinden yararlanarak, fiş görüntüsü bir homografik dönüşüm ile düzlem üzerine düzeltilmektedir

(perspective correction). Bu adım, fişin fotoğraftaki eğimini ortadan kaldırıp kuş bakışı görünüm elde etmek için kritik önemdedir [8]; böylece sonraki OCR adımında metin tanıma başarımı artmaktadır. Perspektif düzeltme sonrasında görüntü, adaptif eşikleme (adaptive thresholding) yöntemiyle siyah-beyaz ikili formata dönüştürülür. Adaptif eşikleme, her bir bölgenin parlaklık dağılımına uyum sağlayarak piksel değerlerini siyah veya beyaza dönüştürür ve bu sayede değişken aydınlatma koşullarında dahi metinlerin belirginleştirilmesini sağlar [9]. Bu aşamaya kadar yapılan işlemler sonucunda, her bir fiş bölgesi OCR için uygun hale getirilmiş yüksek kontrastlı ve düzeltilmiş görüntüler olarak elde edilmiştir.

OCR motoru seçimi ve entegrasyonu konusunda iki alternatif değerlendirilmiştir: Tesseract ve Keras OCR. Yapılan testlerde, Tesseract motorunun özellikle eğrilmiş veya perspektifi bozuk metinlerde beklenen doğrulukta sonuç veremediği gözlemlenmiştir. Bu bulgu, Tesseract'ın klasik yöntemlere dayanması nedeniyle derin öğrenme tabanlı çözümlere kıyasla hassasiyetinin düşük olabileceğini belirten literatür ile de örtüşmektedir [10]. Diğer yandan Keras OCR, Keras ve TensorFlow üzerinde çalışan derin öğrenme tabanlı bir OCR kütüphanesidir ve karmaşık düzenlere sahip belgelerde dahi yüksek doğruluk sunabilmektedir [11]. Özellikle eğik açıyla yazılmış metinlerin tanınmasında başarılı performans göstermiş, ayrıca proje kapsamında kullanılan derin öğrenme altyapısına kolaylıkla entegre edilebilmiştir. Bu nedenlerle OCR aşamasında Keras OCR tercih edilmiş ve fiş görüntülerindeki metinlerin algılanıp dijital metne dönüştürülmesi bu sistemle gerçekleştirilmektedir.

Tanıma adımından elde edilen metinler kullanılarak, fişlerin içerik bazlı sınıflandırılması için kural tabanlı bir anahtar kelime eşleştirme sistemi geliştirilmiştir. Bu sistemde, fiş üzerindeki metin parçaları belirli kategori listelerinde (ör. marka, ürün, hizmet) önceden tanımlanmış anahtar kelimeler ile karşılaştırılmaktadır. Her bir kategori için metindeki eşleşen anahtar kelime sayısı ve önemi dikkate alınarak bir benzerlik skoru hesaplanır. Alınan skorlar arasında en yüksek değere sahip kategori, ilgili fişin sınıfı olarak atanır. Bu yaklaşım, bir metin belgesinde önceden tanımlanmış anahtar kelimeleri tarayarak her bir kategori için skor üreten kural tabanlı sınıflandırma yöntemlerine dayanmaktadır [12]. Örneğin, bir fiş metninde birçok kez geçen belirli marka isimleri o fişin “marka” kategorisinde olduğuna dair yüksek skor üretirken, hizmete dair anahtar kelime bulunmaması diğer kategorilerin skorunu düşük tutar. Bu kural tabanlı sistem, proje kapsamında belirlenen marka, ürün ve hizmet gibi sınıflar için başarılı bir ön ayrıştırma

sağlamıştır.

3.2. Sonraki Aşamada Planlananlar

Bir sonraki aşamada, öncelikle YOLOv5-OBb modelinin eğitimi tamamlanacak ve modelin doğruluk (accuracy) ve ortalama ortalama hassasiyet (mean Average Precision, mAP) gibi metriklerle performansı değerlendirilecektir. Eğitim sonucunda elde edilecek en iyi ağırlıklar kullanılarak tüm test görüntülerinde fiş tespiti yapılacak ve modelin farklı açılardaki ve ışık koşullarındaki fişleri tutarlı şekilde yakaladığı doğrulanacaktır. Gerekirse, veri kümesinin daha fazla örnek veya veri artırma (augmentation) teknikleriyle zenginleştirilmesi planlanmaktadır. Bu sayede modelin genel performansını artırmak ve nadir karşılaşılan desenlere karşı da sağlam olmasını sağlamak hedeflenmektedir. Ayrıca, YOLOv5-OBb ile elde edilen döndürülmüş kutuların, fiş görüntülerinin perspektif düzeltme işlemlerine doğrudan entegre edilmesi değerlendirilecektir. Modelin tespit ettiği dört köşe bilgisi kullanılarak her fiş otomatik biçimde kırılıp düzeltilerek OCR'a verilecek, bu da ön işleme adımlarının tam otomasyonunu sağlayacaktır.

OCR aşaması için Keras OCR entegrasyonunun gerçek dünya fişlerinde kapsamlı testleri yapılacaktır. Farklı yazı tipleri, baskı kaliteleri ve dil bilgisine sahip fişler üzerinde sistem denenecek ve tanıma hataları analiz edilecektir. Bu analiz doğrultusunda, metin tanıma sonuçlarında sık karşılaşılan hatalar için olası düzeltme yaklaşımları planlanmaktadır. Örneğin, rakam ve harf karışıklıkları için özel desen tanıma veya sonuç metinlerine sözlük tabanlı doğrulama (spell-check) uygulanabilir. Keras OCR'nin derin öğrenme modeli gerektiğinde mevcut fiş verilerine uygun olarak ince ayar (fine-tuning) edilecek veya alternatif derin öğrenme tabanlı OCR kütüphaneleri (ör. PaddleOCR, EasyOCR) ile karşılaştırmalı değerlendirmeler yapılacaktır. Amaç, fiş üzerindeki tüm metin alanlarının olabildiğince hatasız şekilde dijitalleştirilmesidir. Bu doğrultuda, OCR çıktılarının manuel olarak doğrulanması ve başarı oranının ölçülmesi de planlanmıştır.

Son olarak, sınıflandırma adımının iyileştirilmesi ve genel sistem entegrasyonu gerçekleştirilecektir. Kural tabanlı anahtar kelime eşleştirme yönteminin farklı fiş tipleri üzerindeki performansı test edilecek ve gerekirse anahtar kelime listeleri genişletilecektir. Özellikle yeni marka veya ürün isimleri eklendikçe bu listeler güncellenecek ve her kategori için ağırlıklandırma kuralları (örneğin bazı anahtar kelimelere daha yüksek puan

verme) gözden geçirilecektir. Ayrıca, sınıflandırma aşamasında bulanık eşleştirme (fuzzy matching) ve metin benzerliği hesaplama gibi tekniklerin entegrasyonu planlanmaktadır. Bu sayede yazım hataları veya kısaltmalar gibi durumlarda da doğru kategorinin tespit edilebilmesi hedeflenmektedir. Geliştirilen sistemin tümleşik olarak uçtan uca çalışması sağlandıktan sonra, geniş bir fiş örnekleminde denemeler yapılarak hassaslık ve duyarlılık (precision-recall) değerleri belirlenecektir. Elde edilen sonuçlara göre son optimizasyonlar gerçekleştirilecek ve proje çıktısı olan fiş tarama ve sınıflandırma aracının, gerçek dünya kullanım senaryolarında kararlı bir şekilde çalışması temin edilecektir.

4. SONUÇLAR

Faturalardan metin çıkarımı ve sınıflandırma amacıyla geliştirilen sistemin hem teknik hem de pratik yönlerden sunduğu avantajlar ele alınacaktır. Ayrıca yapılan çalışmaların hedeflenen sistemin ortaya çıkmasına nasıl katkı sağladığı analiz edilecektir.

OCR ve görüntü işleme teknolojilerinin birlikte kullanılması sayesinde fatura belgelerinden anlamlı veri çıkarımı mümkün hale gelmiştir. Ön işleme adımları ile desteklenen bu süreçte, düşük çözünürlüklü ve bozulmuş belgelerde dahi tatmin edici başarı elde edilmiştir. Uygulanan metodoloji, fatura yapısal belgelerinin otomatik olarak sınıflandırılmasında etkili bir yaklaşım sunmaktadır.

4.1. Genel Değerlendirme ve Kazanımlar

Bu proje, dijital dönüşüm süreçlerinde sık karşılaşılan manuel belge işleme problemlerine çözüm sunmayı hedefleyen yenilikçi bir çalışmadır. Ara rapor sürecinde, projenin teknik altyapısı kurulmuş; OCR teknolojisinin fatura belgeleri üzerindeki uygulanabilirliği test edilmiştir. Uygulanan ön işleme teknikleri sayesinde, düşük kaliteli fatura görsellerinden dahi yüksek doğrulukla metin çıkarımı sağlanabilmiştir.

Projenin bu aşamasında, temel sistemin işlevselliği başarıyla kanıtlanmış, OCR ve ön işleme süreci ile elde edilen çıktılar sınıflandırmaya uygun hale getirilmiştir. Kullanılan açık kaynak yazılımlar sayesinde hem maliyet avantajı sağlanmış hem de özelleştirilebilir bir sistem tasarımı mümkün olmuştur.

Ayrıca projenin sürdürülebilirliği açısından geliştirilen kod yapısı modüler ve genişletilebilir olarak inşa edilmiştir. Bu, ileride sisteme farklı belge türlerinin veya daha gelişmiş sınıflandırma yöntemlerinin kolaylıkla entegre edilebilmesini sağlayacaktır.

Bu aşamaya kadar elde edilen başlıca kazanımlar şunlardır:

- Teknik Bilgi Birikimi: Görüntü işleme, OCR ve makine öğrenmesi konularında uygulamalı deneyim kazanılmıştır.
- Araç ve Teknoloji Kullanımı: Python, OpenCV ve Keras OCR güçlü kütüphanelerle çalışılmış; bu teknolojilerin proje süreçlerine nasıl entegre edileceği öğrenilmiştir.
- Doğruluk Artışı Sağlayan Stratejiler: Geliştirilen ön işleme yöntemlerinin OCR doğruluğuna etkisi sayısal olarak ölçülmüş ve analiz edilmiştir.
- Veri Temizliği ve Hazırlama: OCR sonrası metinlerde yapılan düzeltmelerle analiz edilebilir veri elde edilmesi sağlanmıştır.
- Prototip Oluşturma: Fatura görselinden metin çıkarımı ve bu metinlerin sınıflandırılmasına yönelik temel bir prototip sistem inşa edilmiştir.

Bu kazanımlar, projenin bitirme aşamasında daha karmaşık modellerin geliştirilmesine ve sistemin nihai bir ürün haline getirilmesine zemin hazırlamaktadır.

Bu proje kapsamında yapılan çalışmalar sonucunda OCR tabanlı belge işleme süreçlerine dair önemli deneyimler kazanılmıştır. Görüntü ön işleme adımlarının OCR doğruluğu üzerindeki etkisi gözlemlenmiş ve uygun tekniklerin uygulanmasıyla başarı oranı büyük oranda artırılmıştır.

Python dili ile geliştirilen sistem, açık kaynaklı araçlar kullanılarak oluşturulmuş, böylece hem maliyet avantajı sağlanmış hem de geliştirilebilir bir yapı kurulmuştur. Keras OCR'ın entegrasyonu, görsel iyileştirme adımları ve sınıflandırma altyapısının ilk sürümü başarıyla ortaya konmuştur.

Bu aşamaya kadar yapılanlar projenin teknik temelini güçlü bir şekilde atıldığını göstermektedir. Elde edilen çıktılar, hem akademik hem de sektörel olarak değerlendirilebilir niteliktedir.

Ara raporda fatura belgelerinin OCR ve makine öğrenmesi ile analiz edilmesine yönelik bir sistemin temel adımları ortaya konmuştur. Yapılan çalışmalar, projenin hedeflerine ulaşma yolunda önemli bir temel oluşturmuştur. Geliştirilen OCR sistemi ile metin çıkarımı başarıyla yapılmış ve sınıflandırma için uygun bir zemin hazırlanmıştır.

Bitirme projesinin devamında, daha gelişmiş modellerle sınıflandırma başarımı artırılacak ve sistem nihai kullanıcı için kullanılabilir hale getirilecektir.

KAYNAKLAR

- [1] Doxagon, “Dijital doküman yönetiminde OCR’in önemi,” Doxagon Blog, 2022. [Çevrimiçi]. Erişim: <https://www.doxagon.com/blog/dijital-dokuman-yonetiminde-ocrin-onemi/>
- [2] S. Patel and D. Bhatt, “Abstractive information extraction from scanned invoices (AIESI) using end-to-end sequential approach,” *arXiv preprint arXiv:2009.05728*, 2020. [Çevrimiçi]. Erişim: <https://arxiv.org/abs/2009.05728>
- [3] H. Sönmez and S. Gündüz, “Evrşimsel sinir ağı ve metin benzerliği kullanılarak fatura sınıflandırma sistemi,” *Konya Teknik Üniversitesi Akademik Arşiv Sistemi*, 2020. [Çevrimiçi]. Erişim: <https://gcris.ktun.edu.tr/handle/20.500.13091/142>
- [4] H. X. Hukaixuan, *YOLOv5-OBb: Oriented Object Detection Based on YOLOv5*, GitHub repository, 2022. [Çevrimiçi]. Ulaşılabilir: https://github.com/hukaixuan19970627/yolov5_obb [Erişim: 24 Mart 2025].
- [5] Roboflow Blog, *Rotated Object Detection: How to Detect Angled or Skewed Objects Using Oriented Bounding Boxes*, 2023. [Çevrimiçi]. Ulaşılabilir: <https://blog.roboflow.com/rotated-object-detection/> [Erişim: 24 Mart 2025].
- [6] Clova AI Research, *CORD: Consolidated Receipt Dataset for OCR and Information Extraction*, GitHub repository, 2020. [Çevrimiçi]. Ulaşılabilir: <https://github.com/clovaai/cord> [Erişim: 24 Mart 2025].
- [7] Roboflow Universe, *Receipt Segmentation Dataset*, Roboflow, 2023. [Çevrimiçi]. Ulaşılabilir: <https://universe.roboflow.com/receipt-segmentation/receipt-segmentation-jzoro> [Erişim: 24 Mart 2025].
- [8] LearnOpenCV, *Homography Examples Using OpenCV (Python / C++)*, 2019. [Çevrimiçi]. Ulaşılabilir: <https://learnopencv.com/homography-examples-using-opencv-python-c/> [Erişim: 24 Mart 2025].
- [9] OpenCV Documentation, *Image Thresholding*, v3.4, 2020. [Çevrimiçi]. Ulaşılabilir: https://docs.opencv.org/3.4/d7/d4d/tutorial_py_thresholding.html [Erişim: 24 Mart 2025].
- [10] R. Smith et al., *Tesseract OCR Engine*, GitHub repository, 2024. [Çevrimiçi]. Ulaşılabilir: <https://github.com/tesseract-ocr/tesseract> [Erişim: 24 Mart 2025].

- [11] F. Morales, *Keras-OCR: Optical Character Recognition using Keras and TensorFlow*, GitHub repository, 2021. [Çevrimiçi]. Ulaşılabilir: <https://github.com/faustomorales/keras-ocr> [Erişim: 24 Mart 2025].
- [12] K. S. Nigam, *Rule-Based Text Classification with Python*, Towards Data Science, Medium, 2020. [Çevrimiçi]. Ulaşılabilir: <https://towardsdatascience.com/rule-based-text-classification-with-python-bef264880902> [Erişim: 24 Mart 2025].